Relatório Técnico – Arquitetura de IA com n8n

1. Definição da Abordagem

Proposta escolhida:

Arquitetura com múltiplos agentes de IA que se refinam mutuamente via prompt + agente decisor final.

Justificativa:

A proposta se alinha com o objetivo de aplicar validação cruzada entre modelos com diferentes arquiteturas (Gemini e Mistral), otimizando o diagnóstico clínico com base em dados reais. A arquitetura utiliza três níveis de análise: geração de consulta, raciocínio paralelo com duas IAs e refinamento com um decisor final. O uso do **n8n** facilita a orquestração entre os agentes.

Objetivo:

Criar uma arquitetura que permita interpretar relatos médicos, consultar uma base de dados com casos reais (confirmados), analisar com múltiplas IAs, e gerar uma resposta diagnóstica refinada e confiável.

2. Preparação dos Dados

Dataset utilizado:

symptom2disease

Origem: https://www.kaggle.com/datasets/niyarrbarman/symptom2disease

Validação:

Os dados representam descrições sintomáticas reais e rótulos confirmados de doenças, como dengue. Foram extraídos e armazenados na tabela diagnosticos de um banco **MySQL** para facilitar consultas automáticas com SQL gerado por IA.

3. Construção da Arquitetura

a. Pipeline completo

1. Entrada do Médico (Trigger):

Recebe input textual com possível diagnóstico (ex: "Paciente pode estar com dengue...").

2. Extração da Doença (Ollama):

Um agente especializado extrai a **doença principal mencionada** e gera automaticamente uma consulta SQL no formato:

SELECT * FROM diagnosticos WHERE label LIKE '%Dengue%' LIMIT
5;

3. Consulta no MySQL:

Executa a query para obter os casos reais confirmados da doença.

4. Análise por IA 1 (Ollama - Mistral):

Analisa os sintomas relatados e os compara com os exemplos reais, gerando um parecer clínico com probabilidade estimada.

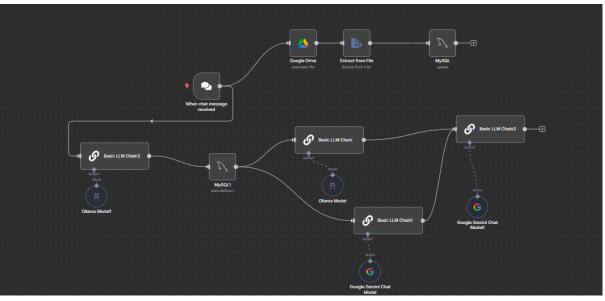
5. Análise por IA 2 (Gemini):

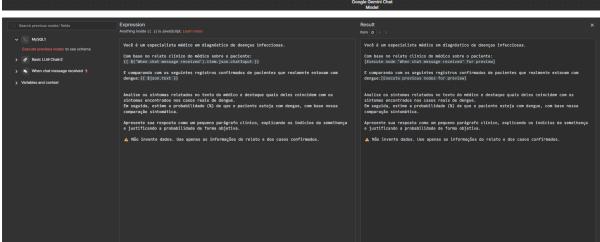
Realiza a mesma análise com outra arquitetura de IA, gerando uma segunda resposta.

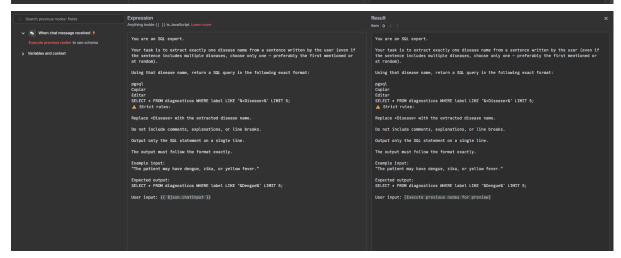
6. Agente Decisor (Gemini via prompt):

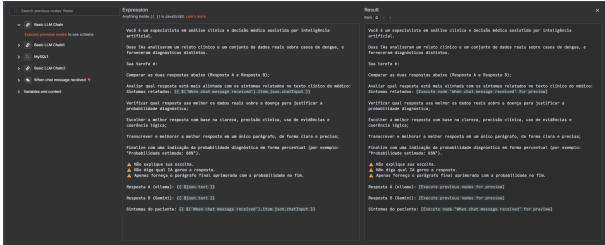
Recebe as duas respostas anteriores e o relato clínico. Avalia a mais precisa, clara e bem justificada, então **refina** a resposta final com a estimativa de probabilidade:

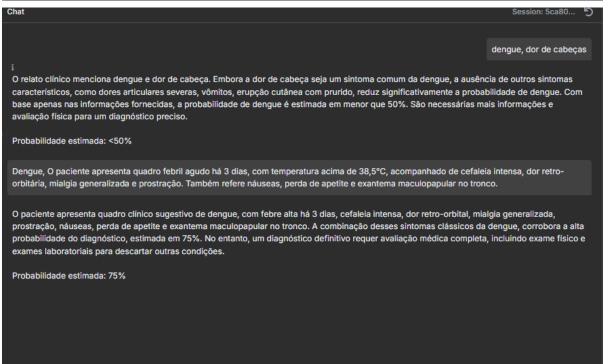
"Os sintomas do paciente coincidem fortemente com os registrados nos casos de dengue, como febre alta, dor de cabeça intensa e mialgia. Probabilidade estimada: 87%."











b. Ferramentas e bibliotecas

- n8n: Automação e orquestração de fluxos
- Google Drive API: Acesso ao dataset
- MySQL: Armazenamento estruturado e consultas
- Ollama (Mistral): Modelo LLM local
- Gemini 1.5 Flash (Google): IA generativa para análise e decisão
- LangChain: integração de modelos com lógica de prompt

4. Teste, Validação e Métricas

Validação:

O sistema foi testado com diferentes relatos clínicos e comparado com os dados reais no banco. A resposta final mostrou-se mais precisa e coerente com o auxílio do agente comparador.

Métricas qualitativas:

- Clareza da resposta: alta
- Uso de evidência (sintomas coincidentes): consistente
- Probabilidade estimada coerente com base de dados

Limitações:

- A resposta depende da qualidade e diversidade do dataset.
- Se o relato médico for vago ou incompleto, a IA pode gerar probabilidade imprecisa.

5. Refinamento e Melhorias

Ajustes realizados:

- Prompt do decisor ajustado para não revelar qual IA foi escolhida.
- Formato da resposta final padronizado com parágrafo + probabilidade.
- Uso de banco vetorial foi considerado, mas optou-se por SQL estruturado para maior interpretabilidade.

6. Dificuldades e Aprendizados

Dificuldades:

- Orquestrar múltiplos modelos com decisões encadeadas no n8n.
- Controlar o formato das respostas geradas para não haver redundância.

Aprendizados:

- A combinação de lAs diferentes pode gerar diagnósticos mais robustos.
- O uso de LLMs como agentes intermediários permite decisões embasadas em critérios explícitos e ajustáveis.